数字人情感陪伴对话模型竞赛实验研究报告

面向情感陪伴对话的轻量化大语言模型专项微调与双 LoRA 协同推理

基于 Qwen3-1.7B 的 QLoRA 训练、任务解耦与本地双 Adapter 部署

作者

甘文杰 南开大学

庄振宇 南开大学

报告时间：2026 年 11 月

摘　要

情感陪伴对话要求语言模型综合当前语句与会话历史，同时完成情绪判断、用户画像提取和自然语言回复生成。由于三类任务分别具有单标签分类、多标签预测和开放式文本生成的特点，统一的自回归训练目标需要兼顾结构化输出与较长的回复文本。在小参数模型与有限显存环境中，如何安排训练监督、提升画像识别能力并完成低成本部署，是本项目的主要研究与实现问题。

本项目选择 Qwen3-1.7B 作为基础模型，构建了涵盖原始数据审计、对话历史裁剪、Chat Template 编码、Completion-only SFT、评测与模型归档的训练流程，利用 4-bit NF4 量化和低秩适配（LoRA）在 RTX 4060 Laptop 8GB GPU 上完成微调。首先建立统一输出情绪、画像和回复的 E01-B 多任务基线；随后通过监督 Token 分布审计、Loss 加权和输出协议探索等实验，分析画像预测的主要困难。在此基础上，形成两条专项训练路线：A8 使用三维画像专用 Prompt 与短文本 Completion，将训练目标集中于 33 个画像标签；E03-B 使用情绪与回复双字段协议，并通过困难情绪样本 Replay 改善类别覆盖。推理阶段共享同一个 Qwen 基座，按任务切换两套 LoRA Adapter，分别生成画像与情绪回复，再由代码转换并组装为完整 JSON。

实验结果表明，E01-B 相比未微调基座在 1,833 条 Dev 预测点上的情绪准确率由 12.82% 提升至 65.36%，画像 Micro-F1 由 7.82% 提升至 42.23%。在相同的 2,354 条 Val 预测点上，A8 P4504 的画像 Micro-F1 为 46.78%，E01-B Train+Dev 为 40.14%；由于两者采用不同的原生 Prompt 与输出协议，该差异用于描述本地候选结果，不作为单因素因果比较。E03-B Replay-1152 在两组本地评测上的情绪准确率为 73.21%（固定 209 点）与 74.13%（新增 201 点），相应比较仍受样本范围和统计不确定性限制。最终双 Adapter 系统完成本地 vLLM 与 Docker 离线验证：固定 100 条输入的输出 Schema 合法率为 100%，端到端延迟 P50/P95 为 3.245/15.237 秒。上述结果均为项目本地代理指标和工程验收结果，不代表官方测试分数。

关键词：情感陪伴对话；Qwen3-1.7B；QLoRA；用户画像；多任务微调；困难样本回放；双 Adapter 推理

目录

摘要 **I**

第一章 研究背景与任务分析 **1**

1.1 研究背景 1

1.2 任务定义与输出协议 1

1.3 总体技术路线与模型选择 2

第二章 数据处理与基础模型训练 **3**

2.1 原始数据审计与清洗 3

2.1.1 数据规模与预测点组织 3

2.1.2 情绪与画像标签分布 3

2.2 多轮历史构造与 Token 预算 4

2.3 QLoRA 与 Completion-only 监督 5

2.3.1 低秩参数训练 5

2.3.2 生成目标与 Loss Mask 6

2.3.3 训练与预测的区别 6

2.4 指标与实验管理 6

第三章 多任务基线与模型优化探索 **7**

3.1 统一多任务基线 E01-B 7

3.2 监督结构与画像预测诊断 7

3.2.1 不同任务的监督 Token 构成 7

3.2.2 画像输出的误报与漏报 8

3.3 优化方向与代表性探索 8

第四章 任务专项微调方法 **9**

4.1 面向画像的生成式专项模型 A8 9

4.1.1 独立 Prompt 与短 Completion 9

4.1.2 训练样本调度与逐步扩展 9

4.1.3 Selective Completion Logits 加速 10

4.2 面向情绪与回复的 E03-B 专项模型 10

4.2.1 双字段输出协议 10
4.2.2 训练档位与质量变化 11
4.2.3 困难情绪样本 Replay 11
4.3 专项方案的模型归档与选择 12

第五章 双 Adapter 协同推理系统 13
5.1 共享基座与串行推理架构 13
5.2 结果解析与 JSON 组装 13
5.3 vLLM 服务与 Docker 离线部署 14

第六章 实验结果与性能分析 15
6.1 画像专项训练的总体效果 15
6.2 情绪识别与回复生成效果 15
6.3 画像困难样本 Replay 的补充比较 16
6.4 系统推理与部署性能 17

第七章 总结与展望 18

附录 A 实验数据来源与版本说明 19

第一章　研究背景与任务分析

1.1　研究背景

情感陪伴对话与一般开放式问答不同。用户的输入往往包含显性情绪、隐含需求和个人表达习惯。例如，“最近准备考试总是睡不好”既可能反映当下的焦虑，也包含考试学习这一兴趣或生活主题；模型在给出回复时，需要结合这类信息回应用户的当前处境。仅生成语法流畅的文本，难以覆盖比赛要求的全部预测维度。

本项目面向数字人情感陪伴对话赛题，研究在一套轻量化语言模型上实现**情绪识别、用户画像提取和情感回复生成**的联合能力。研究关注三个相互衔接的问题：如何将多轮会话构造为可训练样本，如何提升结构化画像标签的预测效果，以及如何在受限算力下将不同专项能力整合为统一推理系统。

1.2　任务定义与输出协议

一个预测点包含标识符及截至当前用户消息的合法会话历史。设历史为

$$H_t = \big[(r_1, u_1), \ldots, (r_t, u_t)\big], \tag{1.1}$$

其中 r_i 表示消息角色，u_i 表示消息文本，t 为当前预测位置。系统需要从 H_t 生成情绪标签 e_t、用户画像 $\boldsymbol{p}_t$ 和回复 a_t。数据还包含历史消息引用字段，最终系统按提交协议组装相应结构。

情绪识别属于 16 类单标签任务，画像由三个维度组成：性格特征（10 类）、兴趣偏好（12 类）和交流风格（11 类），每个维度都允许多个标签。给定 33 维二值标签向量 $\boldsymbol{y}_t \in \{0,1\}^{33}$，某一维度没有被选中的标签时输出空数组；回复则是长度不固定的中文自然语言文本。

表 1.1　项目涉及的核心预测任务及评价目标

任务	预测形式	核心要求
情绪识别	16 类单标签	结合当前用户表达判定主要情绪
用户画像	33 个多标签，三维分组	判断个性特征、兴趣主题与表达风格
情感回复	开放式文本生成	内容自然、与上下文及情绪相符
结果组装	JSON 结构	字段、合法标签、ID 与输出格式符合提交协议

统一模型的完整预测采用如下结构（示例内容仅用于说明协议）：

```
{
  "id": "test_000123_t0",
  "emotion_label": "anxiety",
  "user_profile": {
    "personality_traits": ["sensitive"],
    "interests": ["study_exam"],
    "style": ["direct", "rational"]
  },
  "response_text": " 复习压力比较大时，可以先整理最紧迫的任务。",
  "memory_refs": []
}
```

从任务结构可以看到，情绪与画像需要稳定的离散判别，回复则需要连续的自回归生成。后续训练方案正是围绕这一差异展开。

1.3 总体技术路线与模型选择

项目使用 Qwen3-1.7B 作为统一基座。训练采用 QLoRA：将基座权重量化后冻结，仅更新插入 Transformer 线性层的低秩参数，使训练能在 RTX 4060 Laptop 8GB 显存上运行。项目通过 Python、PyTorch、Transformers/PEFT 完成模型训练与验证，并使用 vLLM 及 Docker 实现本地推理服务交付。

整个研究按照**数据处理—统一基线—监督诊断—专项训练—双路集成—系统验收**逐步推进。统一基线用于建立任务能力；监督诊断用于确定画像改进重点；专项模型分别处理画像与情绪回复；双 Adapter 推理再将两路结果组合为最终输出。

完整研发主线与最终集成节点如图1.1所示。

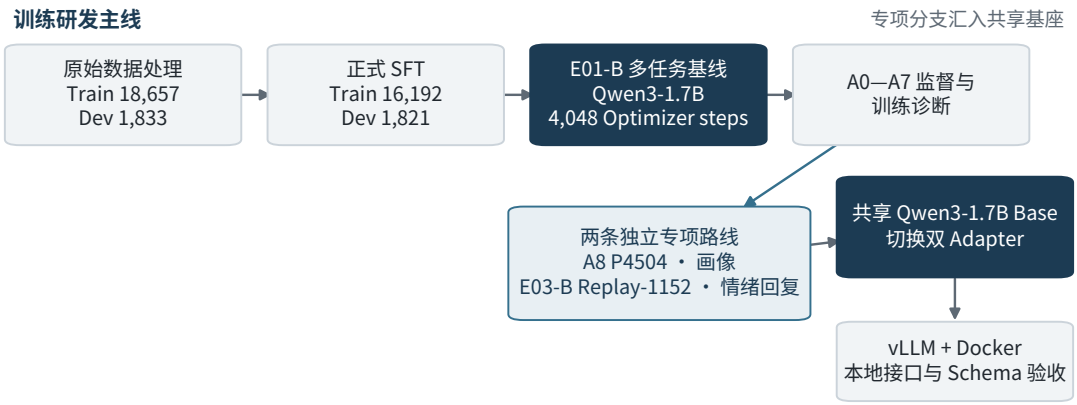


图 1.1 项目研究总体技术路线

数据来源：项目当前状态交接文档；全局实验方案与结果总览。

第二章　数据处理与基础模型训练

2.1　原始数据审计与清洗

2.1.1　数据规模与预测点组织

官方提供的训练集以**对话**为基本存储单位，每段对话内部包含多条用户与助手消息，并设置一个或多个需要模型预测的时刻。因此，训练数据行数与最终的监督样本数并不相同。原始 Train 包含 8,338 段对话、117,902 条 Turn、18,657 个预测点；Val 包含 900 段对话、11,732 条 Turn、2,354 个预测点。

表 2.1　原始数据规模与正式模型训练样本

数据范围	对话数	原始预测点	可用 SFT 点	用途
Train	8,338	18,657	16,192	参数训练
Dev	—	1,833	1,821	开发评测、最终续训
Val	900	2,354	—	本地最终模型比较

说明：Dev 由规范化训练数据划分得到；表中 Train 对话数为原始划分统计，SFT 行数是经过清洗、预算审计及可训练性筛选后的预测点数。Val 2,354 个预测点在最终比较中全部保留为固定评测分母。

数据审计重点包括：官方 Schema 完整性、对话时序、重复样本、回复引用与目标 Turn 的位置关系，以及标签分布。原始 Train 发现 202 条重复对话 Turn 候选、508 个重复预测点候选和 4 个回复时序异常预测点。这些记录通过确定性规则处理，并保留样本 ID 与审计结果，便于定位训练数据来源。清洗流程同时保存每一阶段 Manifest、哈希和排除原因，避免不同实验采用难以追溯的数据口径。

2.1.2　情绪与画像标签分布

训练集的情绪分布具有明显差异。例如，原始 Train 中 `anxiety` 约占 33.98%，`relaxed` 约占 15.11%，而 `care`、`surprise` 和 `disgust` 等类别占比较低。多标签画像也具有较强的稀疏性：在正式有效的 16,192 条 Train 样本中，三维画像均为空的样本为 6,033 条，占 37.26%。

这意味着训练时既要学习何时输出标签，也要学习何时保留空画像；模型若过度保守，会产生大量漏报，若一味增加标签，则可能增加误报。后续画像研究中的 Recall、Precision 和 FP/FN 分析均由此展开。

图2.1并列展示原始 Train 情绪 Gold 频次和有效 SFT Train 的画像稀疏性；两侧统计分母不同。

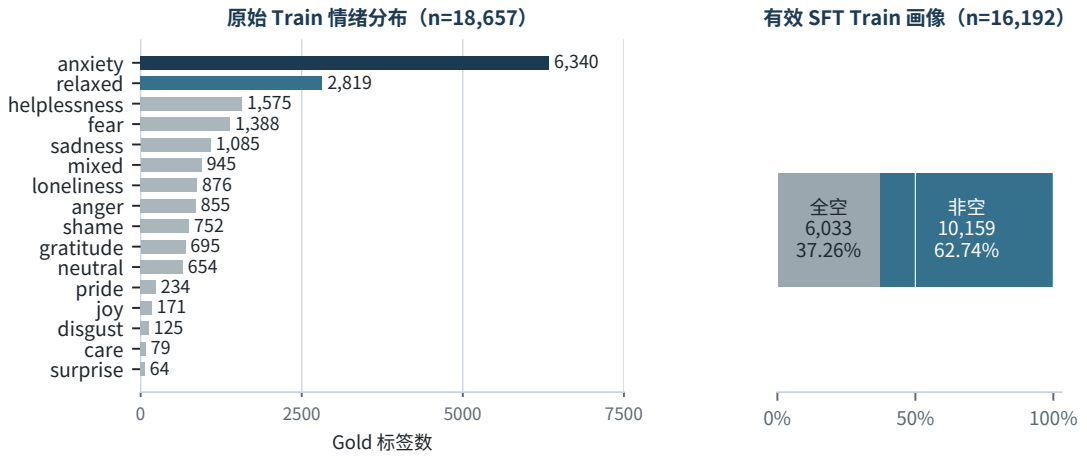


图 2.1 Train 情绪分布与画像稀疏性

数据来源：D0.1 数据质量审计；D0.4.3 监督数据构建与 Batch 验收。原始 Train 为 18,657 个预测点，有效 SFT Train 为 16,192 条。

2.2 多轮历史构造与 Token 预算

一次预测必须只使用当前时刻已出现的会话历史。因此，我们将每个预测点展开为独立训练样本，再按照对话中的角色和时间顺序构造模型输入。训练与推理使用一致的 Chat Template，以保持系统指令、历史消息及 Assistant 起始位置的编码方式稳定。

项目采用 P0/F2/T1 三项基础约定：P0 定义系统任务指令和合法输出字段；F2 固定完整 JSON Completion 的序列化形式；T1 按 Token 预算保留最近的完整历史消息后缀。具体地，训练 Prompt 上限设置为 $P = 1280$ Token，训练完整序列上限为 $S = 2048$ Token。对于长度超限的历史，从较早消息开始移除，保留当前用户消息及时间顺序；超过训练预算的目标序列按既定规则排除。

设系统指令为 s、所选历史为 $\widetilde{H}_t$、编码函数为 ChatTemplate，模型输入 Prompt 为

$$x_t = \text{ChatTemplate}(s, \widetilde{H}_t, \text{assistant_prefix}). \tag{2.1}$$

训练时再拼接标准答案的 Token 序列 y_t，得到完整输入 $[x_t; y_t]$。这一处理保证同一对话不同预测点能够按时间逐步展开，也为后续专项任务的独立 Prompt 提供统一的历史输入来源。

图2.2以人工编写的短对话示意预测点的可见范围、T1 历史裁剪以及 Prompt 与 Completion 的监督边界。

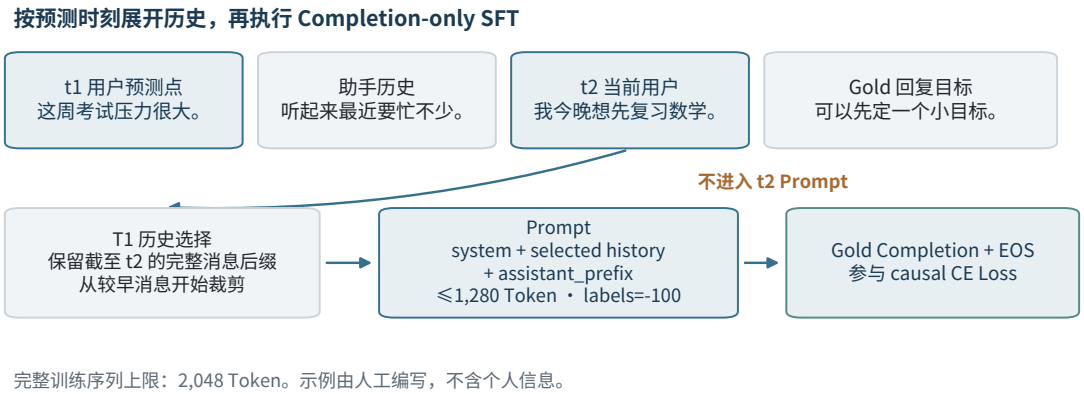


图 2.2　预测点展开、历史截断与 SFT 样本构造

数据来源：D0.4.2 Token 长度审计；D0.4.3 监督数据构建与 Batch 验收；对话内容为人工编写示意。

2.3　QLoRA 与 Completion-only 监督

2.3.1　低秩参数训练

直接更新 1.7B 基座模型的全部参数会增加显存与优化器存储开销。本项目采用 4-bit NormalFloat（NF4）量化基座、BF16 计算和 LoRA 适配器。对于一个原始线性变换 $W \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$，LoRA 通过低秩矩阵 A 与 B 引入可学习增量：

$$h = Wx + \frac{\alpha}{r} BAx, \qquad A \in \mathbb{R}^{r \times d_{\text{in}}}, \quad B \in \mathbb{R}^{d_{\text{out}} \times r}. \tag{2.2}$$

其中 W 被量化并保持冻结，训练只更新 A、B。在正式训练中使用 $r = 8$、$\alpha = 16$、dropout 为 0，并将 LoRA 应用于注意力投影矩阵（`q_proj`、`k_proj`、`v_proj`、`o_proj`）以及前馈网络的 `gate_proj`、`up_proj`、`down_proj`，不设置独立分类头；结构见图2.3。

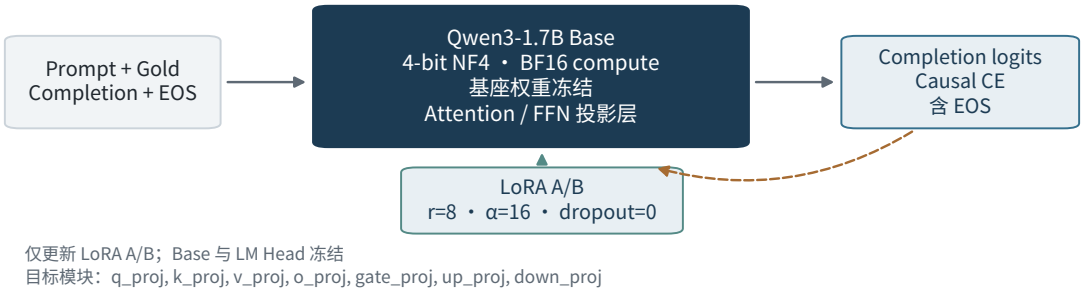


图 2.3　QLoRA 训练结构与参数更新示意

数据来源：E0.1-B 正式 SFT 与 Dev 对照验收报告；NF4、BF16、LoRA r=8、alpha=16、7 个目标模块。

2.3.2 生成目标与 Loss Mask

项目采用自回归监督微调。给定 Prompt x 与目标 Completion $y = (y_1, \ldots, y_T)$，使用 Teacher Forcing，训练目标为

$$\mathcal{L}_{\text{SFT}}(\theta) = -\frac{1}{T}\sum_{i=1}^{T} \log P_\theta(y_i \mid x, y_{<i}). \tag{2.3}$$

为使模型将学习重点放在目标输出上，Prompt 对应的监督标签设为 `-100`，不直接参与交叉熵计算；Completion Token（含 EOS）参与 Loss。虽然 Prompt 自身不计算 Loss，它仍通过 Attention 为后续目标 Token 提供条件信息。实际实现使用 microbatch 1、梯度累积 4，累积四次反向传播后更新一次 LoRA 参数。

2.3.3 训练与预测的区别

训练阶段，标准答案 Token 作为后续位置的真实上下文，模型一次前向即可得到 Completion 各位置的预测 Loss。推理阶段没有标准答案，模型依据当前已生成的 Token 自回归预测，直到 EOS 或生成长度上限。因此，每个实验不仅记录训练 Loss，也在固定预测点上执行真正的生成式评价，以检验输出是否满足合法标签和格式要求。

2.4 指标与实验管理

画像采用 33 个标签的微平均 Precision、Recall 和 F1：

$$P_{\text{micro}} = \frac{TP}{TP+FP}, \qquad R_{\text{micro}} = \frac{TP}{TP+FN}, \qquad F_{1,\text{micro}} = \frac{2TP}{2TP+FP+FN}. \tag{2.4}$$

其中 TP 为正确输出的正标签数，FP 为多输出的错误标签数，FN 为漏掉的 Gold 标签数。Macro-F1 则先求每个标签的 F1，再对 33 类等权平均。情绪使用 Accuracy 和 Macro-F1；回复使用项目实现的字符级 BLEU-4 与 ROUGE-L。评测同时检查格式合法率、EOS 完成率、生成长度和延迟。

各实验使用固定数据快照、配置、种子和 Checkpoint 记录。模型训练、开发评测、最终 Val 对比与部署验收分别保存对应的输入 ID、权重、生成配置和结果摘要，以便解释后续选择的依据。

第三章　多任务基线与模型优化探索

3.1　统一多任务基线 E01-B

在项目初期，我们以同一套 Qwen3-1.7B + LoRA 参数同时学习情绪、画像及回复。一次生成完成所有字段，最后解析为符合比赛要求的 JSON。该设计能够较快建立完整端到端链路，也便于观察三个任务在共享监督下的基础能力。

正式 E01-B 使用 16,192 条有效 SFT Train，训练 4,048 个 Optimizer Steps，学习率 10^{-4}，AdamW 优化器与 constant scheduler。随后在固定 1,833 个 Dev 预测点上，将未微调 Base 与微调后的 Adapter 进行相同协议的对比。

表 3.1　E01-B Full 在相同 Dev 1,833 点上的基线提升

指标	Base	E01-B Full	变化
情绪 Accuracy	12.82%	**65.36%**	+52.54 pp
情绪 Macro-F1	0.0690	**0.4972**	+0.4282
画像 Micro-F1	0.0782	**0.4223**	+0.3441
画像 Macro-F1	0.0724	**0.2700**	+0.1976
字符级 BLEU-4	2.3993	**12.8212**	+10.4219
ROUGE-L	0.1188	**0.2603**	+0.1415

这组结果表明，统一 SFT 能够有效学习领域输出协议，提升情绪判断、画像标签和回复文本的综合质量。与此同时，画像 Micro-F1 仍处于 0.42 左右，成为后续重点改进方向。

3.2　监督结构与画像预测诊断

3.2.1　不同任务的监督 Token 构成

完整 JSON Completion 同时包含较长的回复正文与较短的分类标签。为了解不同任务在训练目标中的相对规模，我们对 16,192 条正式 Train 的监督 Token 做了字段归属统计。回复正文占约 79.26%，画像对象占约 8.89%，情绪标签值占约 1.06%，其余属于公共结构、EOS 与字段边界。

各字段实际监督 Token 份额见图3.1。公共 JSON 结构、边界混合和 EOS 合并为“其他监督 Token”，避免把 Token 份额误读为各字段的 Loss 贡献。

该统计说明，不同输出字段在整体监督序列中占据的 Token 数量差异明显。随后，在固定 128 条 Train 样本上进一步计算 Teacher-forced CE，观察到回复正文的 CE 总和

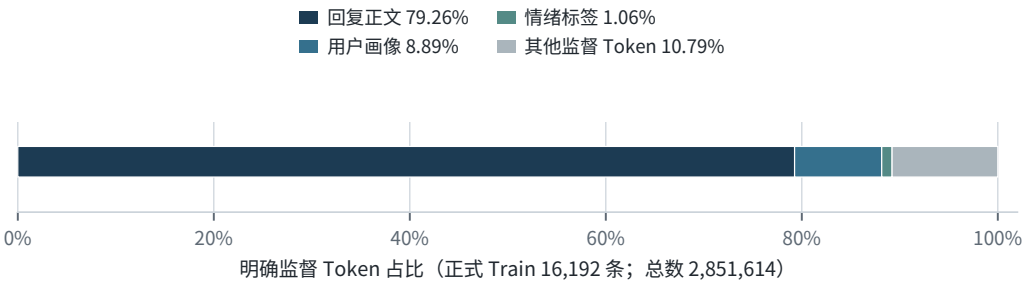


图 3.1　统一 SFT 监督 Token 的字段组成

数据来源：E0.3-A0 监督结构诊断报告；16,192 条正式 Train，共 2,851,614 个明确监督 Token。

在该子样本中同样占较高比例。结合 33 标签分布及空画像现象，我们确定了两个值得继续尝试的方向：一是调整结构化字段的训练关注度，二是使分类目标与长回复目标分别学习。

3.2.2　画像输出的误报与漏报

画像属于多标签任务，评分同时受到误报与漏报影响。分析 E01-B 在不同历史长度下的结果发现，部分用户画像虽然在 Gold 中存在，模型却输出空维度；另一方面，直接放宽标签输出又可能产生额外 FP。因此，我们在探索阶段同时记录 TP、FP、FN、Precision 和 Recall，而不单独追求更高的非空预测比例。

在概率探针、短历史分层与低学习率续训等探索中，模型对于某些标签能够产生更多预测，但误报数量也会随之变化。上述观察促使后续方案采用更明确的任务目标，而不将增加标签输出量作为唯一优化手段。

3.3　优化方向与代表性探索

表 3.2　主要优化探索及其对最终方案的作用

方向	实验思路	形成的经验
字段损失加权（A1）	增强画像字段或标签值的 Token CE 权重	加强局部监督能够改变预测倾向，同时需观察总体 F1 与误报
概率与错误诊断（A2–A4）	冻结模型标签概率、短历史分层、低 LR 续训	更明确地观察漏报、误报与标签边界问题
辅助分类监督（A5、A7）	33 标签 BCE 与独立分类头设计	拓展了专项学习思路与分类评估工具
文本协议简化（A6）	将 JSON 转为固定的字段文本	为后续短 Completion 和确定性解析提供实现基础

A1 在 1,833 条 Dev 上的画像 Micro-F1 为 0.3839，低于统一 SFT 的 0.4223；短程续训虽提高 Recall，也增加 FP，后续因此转向**任务分工与 Completion 监督范围调整**。

第四章　任务专项微调方法

4.1　面向画像的生成式专项模型 A8

4.1.1　独立 Prompt 与短 Completion

A8 专项模型仍使用 Qwen3-1.7B 自回归生成机制，保留通用 Base 与 LoRA，但独立设计画像任务指令，并只监督三个画像维度：

```
Personality=sensitive
Interests=study_exam|reading_writing
Style=direct|rational
```

多标签使用竖线 | 连接，空维度输出 -。模型只生成三行，随后由确定性解析器转换为官方 Schema 的三个数组。与完整多任务输出相比，专项 Completion 不包含情绪标签、长回复正文及记忆字段，使本轮 SFT 的监督位置全部集中在画像输出及其字段结构上。

4.1.2　训练样本调度与逐步扩展

训练使用相同的 16,192 条有效 Train，采用从 Base 新建 LoRA 的方式。在优化后的 A8-V2 训练中，首批 2,048 条样本安排为 1,536 条画像非空样本与 512 条全空样本，通过初期更充分的正标签曝光帮助模型学习非空画像的生成。其余样本以不重复、不遗漏的顺序完成整个 Train。样本选择还关注三维标签覆盖、会话多样性与历史长度。

训练采用 512、1,024、2,048 和 4,048 个累计优化步的阶段式推进，每个阶段保存 Checkpoint，使用固定 Pilot160 与 Dev224 观察生成结果。模型从起初主要输出空画像，逐步学会输出具有实际命中效果的标签；完整 Train 训练结束后，再使用 1,821 条有效 Dev 继续训练 456 步，得到 P4504。

表 4.1　A8 画像模型在固定 Dev224 上的分阶段变化

阶段	训练样本累计	TP	FP	Micro-F1
P512	2,048	6	23	0.0299
P1024	4,096	36	48	0.1576
P2048	8,192	105	61	0.3896
P4048	16,192	137	112	**0.4405**

Pilot160 和 Dev224 是两个独立固定评测集合，图4.1分别连接各自四个实际观测节点，不将两组结果拼成同一曲线。

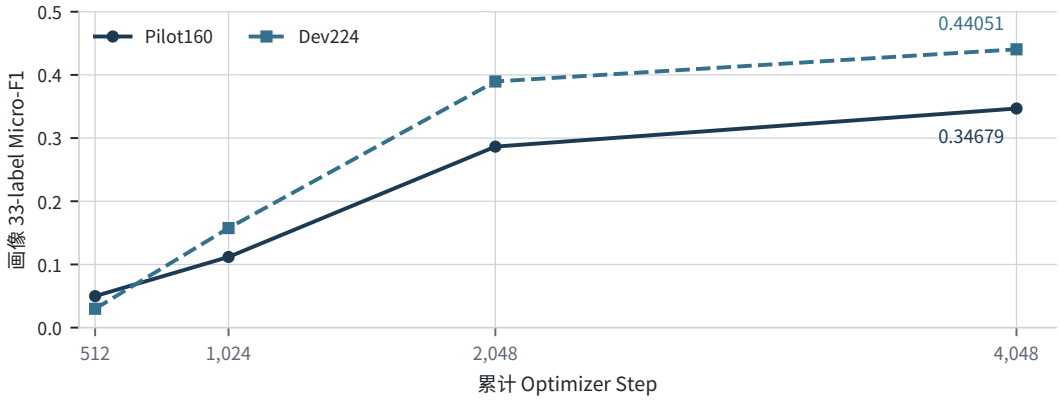


图 4.1 A8 画像专项训练的分阶段 Micro-F1 变化

数据来源：E0.3-A8 V2 分阶段训练观察报告；固定 Pilot160 与 Dev224，累计 Optimizer Step 为 512、1,024、2,048、4,048。

4.1.3 Selective Completion Logits 加速

在生成式 SFT 中，完整 Prompt 需要参与 Transformer 前向计算以形成上下文表示，但 Prompt 位置不参与 Completion Loss。标准 Causal LM 前向会对更多序列位置计算整个词表的 logits。针对这一特点，我们实现了 Selective Completion Logits：先计算 Transformer 的隐藏状态，再提取负责预测 Completion Token 的位置，仅在这些位置通过 LM Head 计算交叉熵。

设完整序列长度为 L、Prompt 长度为 p，隐藏状态为 $h_0, \ldots, h_{L-1}$，则参与目标预测的隐藏状态是

$$\left(h_{p-1}, h_p, \ldots, h_{L-2}\right), \tag{4.1}$$

它们对应的目标 Token 是位置 p 到 $L-1$ 的 Completion（包括 EOS）。这一优化保持 Token 的因果预测关系，减少了无需监督位置的词表映射计算。项目在同样输入和模型条件下比对了新旧 Loss 与 LoRA 梯度，并完成一致性检查。

在 RTX 4060 Laptop 上，A8 P 的配对性能测试由每步 5.396 秒降低到 4.041 秒（约 $1.34\times$ 加速），峰值分配显存由 4.635 GB 降到 2.852 GB。优化后完整 4,048 步的总训练耗时约 16,877 秒。该优化使专项生成式训练能够在较小显存下持续运行。

4.2 面向情绪与回复的 E03-B 专项模型

4.2.1 双字段输出协议

情绪与回复之间存在直接的语义联系：情绪判断用于识别用户当前表达的状态，回复生成则需要围绕该状态产生恰当内容。因此我们将这两个任务放在同一个专项 Adapter 中训练，并使用紧凑的输出协议：

```
emotion=anxiety;response= 最近准备考试压力不小，可以先安排好今天的复习重点。
```

该协议保留单标签情绪和自由文本回复，不再监督画像数组。模型保持 Qwen3-1.7B + QLoRA 的训练方式，使用原有的对话历史处理规则，训练答案由情绪标签与回复正文构成。推理阶段解析第一个 `;response=` 分隔位置，得到情绪和原始回复正文。

4.2.2　训练档位与质量变化

E03-B 使用分阶段 Checkpoint 观察模型收敛过程。在固定 209 个预测点上，Step 512 时情绪准确率为 59.81%，到 Step 2,048 提升至 71.77%，到 Step 4,665 达到 72.25%。与此同时，文本生成长度逐步趋于稳定，BLEU-4 与 ROUGE-L 等本地指标也得到改善。

表 4.2　E03-B 在固定 209 点上的阶段表现

模型档位	情绪 Accuracy	BLEU-4	ROUGE-L	回复长度比
Step 512	0.5981	0.0827	0.2812	1.3720
Step 2048	0.7177	0.1206	0.2939	1.0556
Step 4665	0.7225	**0.1270**	**0.3018**	1.0262
Replay 1152	**0.7321**	0.1192	0.2981	1.0930

4.2.3　困难情绪样本 Replay

在 Step 4665 的错误分析中，`mixed`、`sadness`、`care` 等类别存在明显的漏判。为了加强模型对这些类别的学习，我们从原训练数据中构建困难样本回放集合，提高目标类别的训练曝光频率，同时保留普通类别样本维持整体分布。训练保持原 Adapter 起点、Prompt、学习率及 LoRA 配置，仅改变样本构成。

固定 209 点上的类别命中数见图4.2；柱顶同时给出该类 Gold 数。anxiety 单独标注，不纳入困难类柱图。

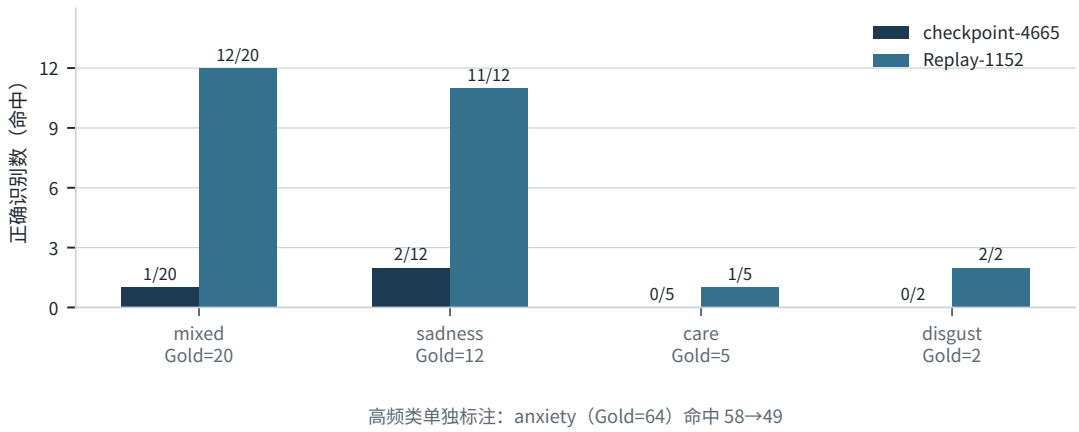


图 4.2　E03-B Replay 前后困难情绪类别的正确识别数量

数据来源：E03-B replay 难例回放实验报告；Step 4665 与 Replay-1152 的固定 Val 209 点类别命中统计。

回放集合中，`care` 和 `disgust` 样本重复四次，`mixed` 与 `sadness` 重复两次，另保留 4,000 条普通样本。总计 6,234 个唯一训练点、8,876 次样本曝光。训练后比较多个 Replay Checkpoint，根据格式合法率、情绪指标和文本指标选择 Replay-1152 作为最终情绪回复 Adapter。

4.3 专项方案的模型归档与选择

最终选择 A8 P4504 作为画像 Adapter，选择 E03-B Replay-1152 作为情绪回复 Adapter。两者均在同一 Qwen3-1.7B Base 上训练，各自保留 Prompt 与生成协议。训练配置、Adapter 权重、Checkpoint 和评测结果按阶段归档，便于回溯训练节点。推理阶段共享一份基础模型，加载两个可切换的增量 Adapter。

第五章　双 Adapter 协同推理系统

5.1　共享基座与串行推理架构

最终系统以一份 Qwen3-1.7B Base 为主干，加载两个 LoRA Adapter。对于每个待预测对话，首先构造 A8 画像专用 Prompt，激活画像 Adapter 并生成三维标签；随后激活 E03-B 情绪回复 Adapter，使用其原生 Prompt 生成情绪及回复。两路预测在同一 GPU 上串行完成，最后将独立结果组合为统一 JSON。

执行顺序与同一 Base 的复用关系如图5.1所示：两种任务分别构造 Prompt，并按序切换 Adapter。

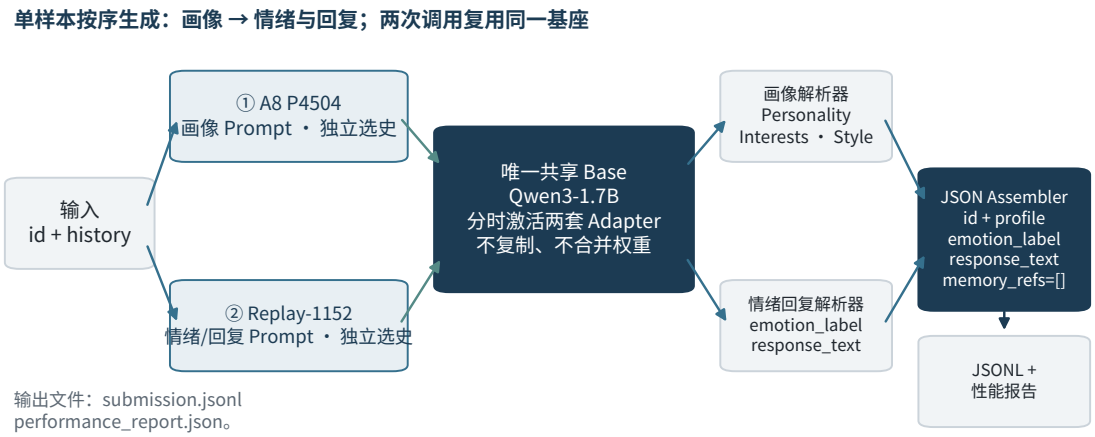


图 5.1　最终共享 Base 双 Adapter 串行推理架构

数据来源：E03 双 Adapter 最终集成与 Docker 验收；participant/README.md。运行输出为 submission.jsonl 与 performance_report.json。

两个 Adapter 在启动时加载完成，推理过程中仅切换激活状态，不需要对每个样本重复读取权重。共享 Base 可以避免同时驻留两个完整模型实例，更符合 8GB 显存条件。项目同时保留每个模型各自的 Prompt 处理逻辑，保证预测输入与相应的训练过程相匹配。

5.2　结果解析与 JSON 组装

两路原生生成协议不同。A8 输出三行画像字段，多个标签用 | 分隔；E03-B 输出 `emotion=...;response=...`。组装模块首先校验标签是否属于合法枚举，然后将 A8 的三行文本转换为三维数组、将 E03-B 的输出解析为情绪和回复，最后填充统一 JSON 结构。

$$\text{Output}(H_t) = \text{Assemble}\big(\text{Parse}_P(f_{\theta_P}(H_t)),\ \text{Parse}_{ER}(f_{\theta_{ER}}(H_t))\big). \tag{5.1}$$

其中 f_{θ_P} 与 $f_{\theta_{ER}}$ 共用 Base，但分别激活独立 LoRA。解析模块还负责字段缺失、非法标签和长度上限等情况的确定性处理，使最终输出始终保持可检查的数据结构。记忆引用字段按最终提交协议填充空数组。

5.3 vLLM 服务与 Docker 离线部署

工程部署采用 vLLM 0.11.1 的多 LoRA 能力，将两个 Adapter 注册为不同别名；对每条样本顺序发送两路生成请求，收集结果并组装 JSON。系统保留固定的官方调用入口 `start.sh`（两个参数：输入文件与输出目录），接收输入文件与输出目录，生成 `submission.jsonl` 和 `performance_report.json`。

在运行工程上，我们完成了显存预算、离线模型打包、容器内入口适配、推理异常处理、模型权重身份核验与镜像回导测试。最终镜像同时包含 Base、两个 Adapter、Tokenizer、Prompt、推理代码和必要的运行环境，便于脱离训练环境进行评测。

第六章　实验结果与性能分析

6.1　画像专项训练的总体效果

为比较最终画像候选，我们将统一多任务 E01-B 与专项 A8 都训练至 Train+Dev，并在同一组 2,354 个 Val 预测点上评价 33 标签画像。E01-B 采用完整 JSON 生成目标，A8 则使用三行画像专项输出。两者使用相同 Val ID 与指标定义，但原生 Prompt 和输出协议不同，因此结果用于候选比较，不构成单因素消融。

表 6.1　相同 Val 2,354 点上的最终画像性能比较

指标	E01-B Train+Dev4504	A8 P4504
画像 Micro-F1	0.4014	**0.4678**
画像 Macro-F1	0.2532	**0.3128**
Precision	0.3451	**0.5156**
Recall	**0.4796**	0.4280
TP / FP / FN	1496 / 2839 / 1623	1335 / 1254 / 1784
三维 Exact Match	19.50%	**37.72%**
Personality Micro-F1	0.3770	**0.4479**
Interests Micro-F1	0.5099	**0.6736**
Style Micro-F1	0.3790	**0.3894**

由表6.1可见, A8 的画像 Micro-F1 测得值高 0.0664, 三维完全匹配率也更高。E01-B 识别出的正确标签数略多，但同时输出更多不属于 Gold 的标签；A8 的 Precision 测得值较高，FP 从 2,839 降至 1,254。逐维度看，A8 在三个维度上的测得 F1 均较高，其中 Interests 的差值最大。鉴于两种方法使用不同的生成协议，这些差值不能单独归因于训练目标。

各维度与总体结果如图6.1所示；分母均为相同的 2,354 个 Val 预测点。

从项目需求看，画像预测既需要一定覆盖率，也要尽量减少无依据的标签。当前结果支持将 A8 作为最终画像模块，并继续保留 E01-B 作为完整任务的独立候选与对照。

6.2　情绪识别与回复生成效果

E03-B 在固定 209 点和与之零重叠的新增 201 点上比较 Step 4665 与 Replay-1152。Replay-1152 的情绪 Accuracy 分别为 73.21% 与 74.13%，对应 Step 4665 的 72.25% 与 67.66%。209 点上净增 2 条，McNemar 检验 $p = 0.892$，配对 bootstrap 95% 区间为 $[-0.057, 0.077]$；新增 201 点上净增 13 条，$p = 0.066$，区间为 $[0.000, 0.129]$。合并 410

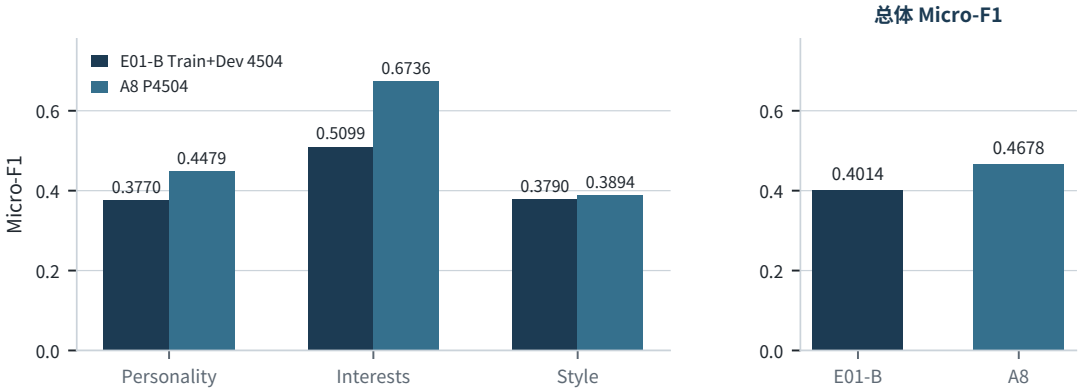


图 6.1 E01-B 与 A8 的三维画像 F1 对比

数据来源：E01-B TrainDev Val 最终对照；E0.3-A8 DevFT 至 Val 评测；同一冻结 Val ID 集合，共 2,354 点。

点后净增 15 条，$p = 0.155$。两批差值方向一致，但均未达到稳健显著证据；类别命中变化是局部切片观察，不能据此宣称 Replay 确定带来泛化提升。BLEU-4、ROUGE-L 和长度比用于补充观察回复质量。

表 6.2 E03-B Replay 1152 的两组情绪回复结果

评测集	模型	情绪 Accuracy	BLEU-4	ROUGE-L	长度比
209 点	4665	0.7225	0.1270	0.3018	1.0262
209 点	Replay1152	**0.7321**	0.1192	0.2981	1.0930
201 点	4665	0.6766	0.1267	0.3058	0.9311
201 点	Replay1152	**0.7413**	0.1338	0.3144	0.9893

这组结果显示 Replay-1152 在两批本地切片上的 Accuracy 差值方向一致，但配对检验与区间仍保留较大不确定性。训练前冻结的档位规则在格式门槛通过者中优先选择 Accuracy 较高的 Checkpoint，因此最终集成采用 Replay-1152；这一工程选择不等同于统计上确认其普遍优于 Step 4665。

6.3 画像困难样本 Replay 的补充比较

在画像训练完成后，我们也测试了基于当前模型错误进行困难样本 Replay 的方案。该试验从已经训练好的 P4504 出发，在固定 `val_gate` 528 个预测点上比较了原模型与增加 128 步训练的 Replay 候选。原 P4504 的画像 Micro-F1 为 0.4914，Replay128 为 0.4133。根据预设的阶段门槛，实验在 Pilot 后停止，并继续保留原始 P4504。

这一结果帮助我们明确最终模型选择：在现有训练预算下，A8 的完整专项训练结果已经形成稳定的画像候选，继续增加困难样本曝光未必能够同时改善漏报与误报；因此最终采用已经完成 Train+Dev 训练的 P4504，并将 Replay Pilot 作为训练策略探索记录。

6.4　系统推理与部署性能

最终双 Adapter 系统在本地 vLLM 和 Docker 环境中完成了测试。本文采用最终 Docker Run 03（E03-DUAL-20261109-03）的固定 100 条 target-free 输入：Schema、ID、双路格式、Prompt Token 身份与 Adapter 路由均通过 100/100 检查，未解决错误、OOM 与未处理截断均为 0。该结果是本地工程验收，不是官方隐藏测试的评分结果。

表 6.3　最终 Docker 双 Adapter 固定 100 条本地压力测试

检查内容	结果
基础模型／部署方案	Qwen3-1.7B + 两套 LoRA，vLLM 0.11.1
有效输出及 Schema	100/100
两路 Prompt ／ Adapter 路由	100/100
端到端 P50 / P90 / P95	3.245 / 10.206 / 15.237 秒
GPU 峰值显存	7,756 / 8,188 MiB
推理错误 / 未解决截断 / OOM	0 / 0 / 0
离线镜像大小	约 31.96 GB（镜像虚拟大小）

来源：Docker Run 03 原始性能记录。P50 与 P95 为记录值；P90 由保存的 100 条样本延迟按最近秩法计算。

图6.2展示 Run 03 的延迟分位数、Schema 合法率和 GPU 峰值分配。

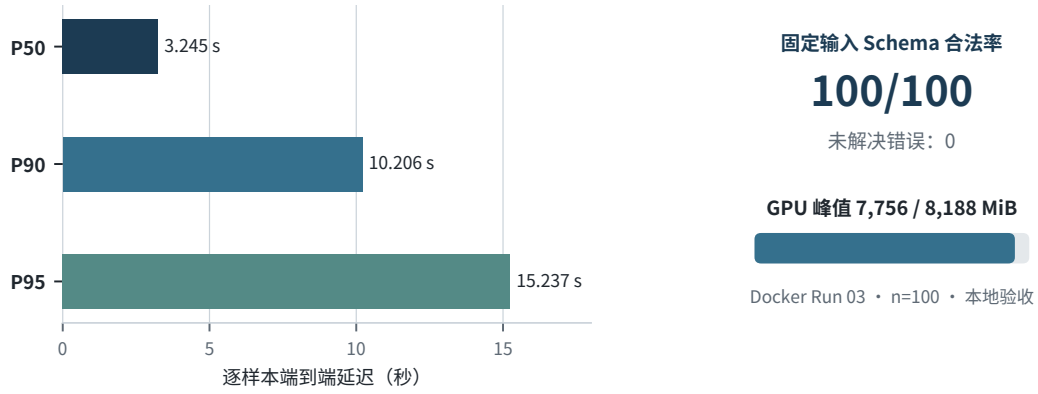


图 6.2　最终双 Adapter 推理延迟与系统验收

数据来源：E03-DUAL-20261109-03 的 performance_report.json 与 verify-output.json；固定 100 条本地输入；P90 按原始延迟最近秩法计算。

最终 Docker 镜像经过保存、回导和离线 GPU 验证，固定 20 条与 100 条输入均满足本地运行契约。由此，项目完成了从训练模型、整合两套 Adapter 到独立环境可执行推理的完整工程流程。

第七章　总结与展望

本项目围绕情感陪伴对话中的情绪识别、结构化用户画像和自然语言回复生成，在 Qwen3-1.7B 基础上完成了从数据处理到最终部署的全流程实践。首先构建统一多任务 QLoRA 基线，在 Dev 上明显提升三项任务的基础能力；随后通过监督 Token 分析、Loss 与输出协议探索，确定画像预测的进一步优化重点。A8 采用画像专项 Prompt 与短 Completion 训练后，在最终 Val 上取得 46.78% 的画像 Micro-F1；该结果与 E01-B 的本地比较采用相同 Val ID，但生成协议不同。E03-B Replay-1152 在固定切片上改善了部分目标类别的命中数，配对统计仍不足以确认稳定的总体提升。

在系统层面，我们采用共享 Base 的双 LoRA 方案，实现两种任务模型的串行调用、字段解析与 JSON 组装，并完成 vLLM、Docker 的本地离线推理验证。项目的主要收获是：对于同时包含短标签分类和长文本生成的应用场景，可以围绕任务特点设计不同的训练目标，再在推理阶段完成轻量化协同。这样既保留了语言模型的表达能力，也为结构化任务提供更直接的优化空间。

后续可以从三个方向继续完善：进一步规范画像标签的判定边界，提升细粒度风格和性格标签的识别；围绕长对话设计更细致的历史信息选择与用户特征维护策略；在现有双 Adapter 架构上优化请求调度与缓存管理，进一步降低端到端延迟。这些方向均可延续当前的训练、评分和模型归档流程，为轻量化情感陪伴系统提供进一步的工程基础。

附录 A　实验数据来源与版本说明

报告数值依据项目保存的实验文档和用户提供的资料包整理，采用本地代理指标口径；表中每个关键数值均附有对应数据范围，以便复核。正文中的训练与评测结果分别来自以下项目记录：

研究内容	对应项目记录（详见资料包内同名前缀文档）
数据审计	D0.1 数据质量审计报告；D0.3 数据构建报告
数据预算与 SFT 构造	D0.4.2 Token 长度审计；D0.4.3 监督数据与 Batch 验收
统一基线	E0.1-B 正式 SFT 与 Dev 对照；E0.1-B Full 深度诊断
监督诊断	E0.3-A0 监督结构诊断；E0.3-A0.1 画像标签与细粒度监督诊断
画像专项训练	E0.3-A8 V2 分阶段训练观察；E0.3-A8 DevFT 至 Val 评测
画像模型对比	E01-B TrainDev Val 最终对照与收尾
情绪回复专项训练	E03-B 稠密半四档汇总；E03-B replay 难例回放实验报告
最终部署	E03 双 Adapter 最终集成与 Docker 验收